Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Syarif Hidayatullah
124400082
Teknik Telekomunikasi, ITERA
syarif.124400082@student.itera.ac.id

Aura Ikhwat Riharja
124400010
Teknik Telekomunikasi, ITERA
aura.124400010@student.itera.ac.id

Revana Tiara Oksanda
124400019
Teknik Telekomunikasi, ITERA
revana.124400019@student.itera.ac.id

***Abstract*—Prediksi trafik internet seluler per jam membantu operator merencanakan kapasitas jaringan. Studi ini membandingkan ANN, RNN, LSTM, dan GRU pada data Telecom Italia di kotak Duomo, Milan, serta menguji seberapa besar hasilnya bergantung pada pilihan hyperparameter. Dengan studi ablasi, satu faktor diubah dari konfigurasi acuan dalam satu waktu: panjang jendela, ukuran hidden, jumlah lapisan, *learning rate*, dan kelompok fitur, ditambah dropout dan gradient clipping sebagai faktor pilihan. Setiap konfigurasi dilatih dengan tiga seed dan dilaporkan sebagai rata-rata $\pm$ simpangan baku; konfigurasi terbaik dipilih dengan MAE validasi. Pada konfigurasi acuan, RNN memberi test MAE terbaik, yaitu 230 ± 5, turun sekitar 51% dari baseline naif terbaik (468), sedangkan ANN paling lemah dengan 310 ± 6. Ablasi menunjukkan bahwa *learning rate*, jumlah lapisan (khusus LSTM), panjang jendela (khusus ANN), dan kelompok fitur berpengaruh jauh lebih besar daripada selisih antar model pada acuan, sedangkan *dropout* justru memperburuk semua model. Pada 10^{-2} urutan model berubah: GRU dan LSTM mengungguli RNN. Menggabungkan nilai terbaik per faktor hanya membantu ANN dan LSTM (test MAE turun sekitar 6% dan 11%), tidak membantu RNN, dan hanya LSTM yang tetap membaik di lokasi kelompok. Kode dan seluruh hasil run tersedia secara publik.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

Operator seluler perlu meramal trafik tiap sel beberapa jam ke depan untuk mengatur kapasitas, menghemat energi, dan mendeteksi lonjakan tak wajar. Trafik per jam berpola harian dan mingguan, sehingga model yang membaca urutan waktu secara alami menjadi kandidat: RNN sederhana, LSTM [1] yang memakai gerbang dan sel memori, dan GRU [2] yang lebih ringkas. Sebagai pembanding, ANN membaca seluruh jendela waktu sekaligus tanpa konsep urutan.

Perbandingan satu konfigurasi saja belum cukup, karena hasilnya bisa banyak ditentukan oleh pilihan hyperparameter. Studi ablasi menjawabnya dengan mengubah satu faktor dalam satu waktu dari konfigurasi acuan. Kontribusi laporan ini:

- ablasi lima faktor wajib dan 2 faktor pilihan pada empat arsitektur, masing-masing dengan tiga seed;
- konfigurasi terbaik per model yang dipilih memakai data validasi, lalu diuji pada minggu test dan Natal;
- uji generalisasi ke lokasi lain (Stazione Centrale, kode 0).

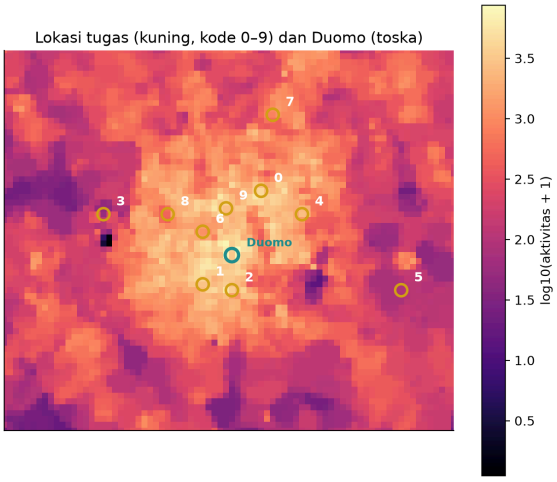


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3] dalam versi per jam [4], mencakup 4 November sampai 29 Desember 2013 (delapan minggu). Fitur yang dipakai adalah aktivitas internet (*net*), panggilan (*call*), dan SMS (*sms*) per kotak, ditambah empat fitur siklis jam dan hari. Target adalah *net*. Bagian 0 sampai C memakai kotak Duomo (5060), dan uji generalisasi memakai lokasi kelompok, yaitu Stazione Centrale (kode 0, kotak ISI-NOMOR-KOTAK), seperti pada Gambar 1.

B. Pembagian Data dan Praproses

Data dibagi menurut waktu: latih 11 November–8 Desember (672 jam), validasi 9–15 Desember, test 16–22 Desember, dan Natal 23–29 Desember. Minggu pertama (4–10 November) hanya menjadi konteks bagi jendela awal. Setiap fitur distandarisasi dengan rata-rata dan simpangan baku dari data sebelum minggu validasi, sehingga tidak ada informasi masa depan yang bocor. Sampel dibentuk dengan jendela geser: masukan adalah W jam terakhir seluruh fitur, dan keluaran adalah *net* pada jam berikutnya. Data tidak boleh diacak karena jam-jam bertetangga sangat berkorelasi; pengacakan menaruh jam yang bersebelahan di set latih dan set uji, sehingga akurasi tampak lebih baik daripada kenyataan saat model benar-benar meramal masa depan.

TABLE I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

C. Model dan Konfigurasi Acuan

ANN meratakan jendela $W \times 7$ fitur, melewatkannya ke lapisan tersembunyi berfungsi ReLU, lalu ke satu keluaran. RNN, LSTM, dan GRU menumpuk lapisan rekuren, mengambil *hidden state* pada jam terakhir, dan memetakannya ke satu keluaran dengan lapisan linear. LSTM memiliki empat gerbang dan GRU tiga, sehingga pada ukuran *hidden* yang sama LSTM memiliki sekitar empat kali dan GRU sekitar tiga kali parameter RNN. Karena itu ukuran *hidden* acuan dibedakan per model agar parameter rekuren setara, sekitar 5,5 ribu (Tabel I). Seluruh model diimplementasikan dengan PyTorch [5].

D. Protokol Ablasi dan Evaluasi

Setiap percobaan hanya mengubah satu faktor dari acuan. Faktor wajib (Bagian A) adalah panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam, ukuran *hidden* $\{16, 32, 64, 128\}$, jumlah lapisan $\{1, 2, 3\}$, *learning rate* $\{10^{-4}, 10^{-3}, 10^{-2}\}$, dan kelompok fitur (*net*; *net+call+sms*; *net+waktu*; semua). Faktor pilihan (Bagian B) adalah dropout (0; 0,2; 0,5); gradient clipping (tanpa clipping; 0,5; 1,0 pada lr = 0,01).

Faktor dropout dipilih untuk mengetahui apakah regularisasi dapat mengurangi overfitting dan meningkatkan kemampuan generalisasi model. Hipotesis awalnya, penggunaan dropout sebesar 0,2 dan 0,5 diperkirakan dapat mengurangi overfitting sehingga menghasilkan nilai MAE yang lebih rendah dibandingkan tanpa dropout.

Faktor gradient clipping dipilih untuk mengetahui pengaruh pembatasan gradien terhadap kestabilan proses pelatihan, terutama pada learning rate yang tinggi. Hipotesis awalnya, gradient clipping dengan batas 0,5 dan 1,0 diperkirakan dapat mencegah gradien yang terlalu besar sehingga proses pelatihan menjadi lebih stabil dan menghasilkan prediksi yang lebih baik.

Setiap konfigurasi dilatih dengan tiga seed (0, 1, 2) dan dilaporkan sebagai rata-rata $\pm$ simpangan baku. Pelatihan memakai *early stopping* pada MSE validasi dan mengembalikan bobot terbaik. Metrik yang dicatat adalah MAE, RMSE, dan MAPE pada skala asli, dengan MAE sebagai metrik utama. Konfigurasi terbaik dipilih hanya dengan MAE validasi; minggu test dan Natal dipakai khusus untuk pelaporan akhir. Seluruh run dijalankan di Google Colab dengan GPU T4: total 273 konfigurasi-seed unik dengan waktu pelatihan kumulatif sekitar 16 menit.

TABLE II
MAE BASELINE NAIF DI DUOMO, HORIZON 1 JAM.

Tebakan naif	Val	Test	Natal
Nilai terakhir	663	601	431
Kemarin	595	552	921
Minggu lalu	493	468	1426

TABLE III
HASIL KONFIGURASI ACUAN DI DUOMO (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED).

Model	Param.	Val MAE	Test MAE	Natal MAE
ANN	6497	249 ± 9	310 ± 6	680 ± 52
RNN	5305	206 ± 7	230 ± 5	421 ± 2
LSTM	5578	230 ± 12	274 ± 25	586 ± 57
GRU	5397	208 ± 4	237 ± 9	468 ± 22

III. HASIL

A. Baseline Naif dan Acuan

Tiga tebakan naif tanpa pembelajaran (nilai jam terakhir, nilai jam yang sama kemarin, dan jam yang sama minggu lalu) menjadi batas bawah (Tabel II). Pada minggu test, tebakan terbaik adalah minggu lalu dengan MAE 468. Pada minggu Natal, tebakan minggu lalu justru memburuk menjadi 1426, karena pola hari libur berbeda dari minggu sebelumnya, sedangkan nilai jam terakhir lebih baik (431).

Keempat model pada konfigurasi acuan mengalahkan baseline naif terbaik pada minggu test (Tabel III). Urutan test MAE dari terbaik adalah RNN, GRU, LSTM, ANN. Selisih RNN dan GRU (8) berada di dalam rentang simpangan baku antar seed, sehingga keduanya tidak dapat dibedakan dengan yakin. LSTM paling bervariasi antar seed (simpangan baku 25). Pada minggu Natal hanya RNN (421 ± 2) yang berada di bawah baseline naif terbaik minggu itu (431); ANN dan LSTM jauh di atasnya, sehingga model yang dilatih pada minggu biasa tidak otomatis kuat pada hari libur.

B. Ablasi Wajib

Tabel IV merangkum seluruh ablasi dan Gambar 2 menunjukkan grafiknya. Angka tebal adalah nilai dengan MAE validasi terbaik untuk model tersebut dalam satu faktor.

Panjang jendela (A1). Menaikkan W dari 24 ke 168 jam menambah parameter ANN dari sekitar 6,5 ribu menjadi sekitar 38,8 ribu, sedangkan parameter model rekuren tidak berubah. Jendela yang lebih panjang tidak selalu lebih baik. ANN memburuk tajam: val MAE naik dari 212 ($W = 6$) menjadi 298 ($W = 168$) dan test MAE dari 269 menjadi 402, sementara epoch berhenti makin dini (167 menjadi 76), tanda cepat *overfit* karena 1176 masukan harus dipelajari dari hanya 672 sampel. Model rekuren hampir tidak terpengaruh: RNN berkisar 200–215 (val) dan GRU 207–213. Val MAE terbaik: ANN $W = 6$, RNN dan GRU $W = 48$, LSTM $W = 6$, tetapi

TABLE IV
ABLASI SATU FAKTOR DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED). TEBAL: NILAI DENGAN VAL MAE TERBAIK PER MODEL DALAM SATU FAKTOR.

Faktor	Nilai	Val MAE				Test MAE			
		ANN	RNN	LSTM	GRU	ANN	RNN	LSTM	GRU
W (jam)	6	**212 ± 6**	215 ± 4	**227 ± 4**	213 ± 11	269 ± 18	229 ± 5	276 ± 15	250 ± 1
	12	238 ± 4	207 ± 6	236 ± 2	209 ± 10	308 ± 13	233 ± 11	303 ± 17	246 ± 14
	24	249 ± 9	206 ± 7	230 ± 12	208 ± 4	310 ± 6	230 ± 5	274 ± 25	237 ± 9
	48	262 ± 3	**200 ± 5**	249 ± 22	**207 ± 5**	333 ± 21	225 ± 12	304 ± 27	237 ± 11
	168	298 ± 18	205 ± 10	241 ± 8	207 ± 5	402 ± 13	234 ± 5	293 ± 20	237 ± 11
Hidden	16	258 ± 28	247 ± 6	244 ± 18	217 ± 21	312 ± 19	253 ± 9	295 ± 13	247 ± 10
	32	249 ± 9	219 ± 7	241 ± 21	210 ± 1	310 ± 6	245 ± 4	291 ± 21	233 ± 5
	64	238 ± 17	**207 ± 13**	218 ± 2	198 ± 9	316 ± 24	241 ± 15	269 ± 13	225 ± 13
	128	**234 ± 1**	208 ± 7	**207 ± 8**	**189 ± 4**	297 ± 32	235 ± 19	246 ± 7	220 ± 11
Lapisan	1	**241 ± 8**	**206 ± 7**	**230 ± 12**	208 ± 4	311 ± 11	230 ± 5	274 ± 25	237 ± 9
	2	249 ± 9	207 ± 9	255 ± 14	**203 ± 10**	310 ± 6	228 ± 8	309 ± 21	239 ± 6
	3	249 ± 12	225 ± 13	339 ± 17	212 ± 16	301 ± 27	246 ± 19	413 ± 54	264 ± 11
Learning rate	0.0001	295 ± 5	285 ± 14	399 ± 25	398 ± 9	340 ± 22	288 ± 7	373 ± 14	356 ± 8
	0.001	**249 ± 9**	**206 ± 7**	230 ± 12	**208 ± 4**	310 ± 6	230 ± 5	274 ± 25	237 ± 9
	0.01	262 ± 17	223 ± 12	**216 ± 14**	208 ± 6	309 ± 53	241 ± 6	226 ± 4	216 ± 11
Fitur	net	261 ± 6	245 ± 6	266 ± 6	265 ± 7	272 ± 14	254 ± 2	285 ± 17	271 ± 11
	net+call+sms	260 ± 5	224 ± 2	244 ± 7	232 ± 13	316 ± 12	228 ± 2	263 ± 11	251 ± 9
	net+waktu	**249 ± 8**	223 ± 10	231 ± 4	213 ± 18	302 ± 7	245 ± 22	293 ± 25	240 ± 25
	semua	249 ± 9	**206 ± 7**	**230 ± 12**	**208 ± 4**	310 ± 6	230 ± 5	274 ± 25	237 ± 9
dropout	0.0	**249 ± 9**	**206 ± 7**	**230 ± 12**	**208 ± 4**	310 ± 6	230 ± 5	274 ± 25	237 ± 9
	0.2	285 ± 43	240 ± 24	234 ± 5	212 ± 5	332 ± 32	251 ± 19	275 ± 13	238 ± 15
	0.5	353 ± 46	273 ± 16	259 ± 15	241 ± 11	368 ± 44	273 ± 18	300 ± 14	259 ± 16
clip (lr = 0,01)	None	262 ± 17	**223 ± 12**	216 ± 14	**208 ± 6**	309 ± 53	241 ± 6	226 ± 4	216 ± 11
	0.5	251 ± 14	234 ± 1	**213 ± 4**	218 ± 17	304 ± 6	232 ± 8	232 ± 4	219 ± 19
	1.0	**248 ± 8**	234 ± 2	224 ± 21	211 ± 10	321 ± 21	234 ± 14	226 ± 2	223 ± 6

selisihnya pada model rekuren berada dalam simpangan baku antar seed. Hasil GRU untuk $W = 24, 48, 168$ nyaris identik (val 208, 207, 207), yang menunjukkan GRU praktis tidak memanfaatkan riwayat lebih dari sekitar 24 jam.

Ukuran hidden (A2). Pada rentang yang diuji, ukuran *hidden* yang lebih besar justru membantu, bukan menyebabkan *overfit*: test MAE terbaik keempat model ada di hidden 128, dan GRU membaik dari 247 (hidden 16) menjadi 220 (hidden 128). Pada hidden 128, jumlah parameter LSTM (70 ribu) sekitar empat kali RNN (17,7 ribu) dan GRU (52,7 ribu) sekitar tiga kali, sehingga membandingkan model pada hidden yang sama bukan perbandingan setara. RNN sudah jenuh pada hidden 64 (val 207 dan 208 untuk hidden 64 dan 128). Pada hidden 16, GRU hampir mencapai batas 300 epoch (rata-rata 292), jadi hasilnya mungkin belum konvergen.

Jumlah lapisan (A3). Menumpuk lapisan tidak membantu. LSTM paling terpengaruh: val MAE 230, 255, 339 dan test MAE 274, 309, 413 untuk 1, 2, 3 lapisan, dengan parameter naik dari 5,6 ribu menjadi 23,5 ribu. RNN memburuk pada tiga lapisan (val 225), GRU praktis datar (val 208, 203, 212), dan ANN tidak berubah. Epoch rata-rata RNN turun dari 164 menjadi 96, konsisten dengan model yang lebih dalam berhenti lebih cepat.

Learning rate (A4). Pada 10^{-4} semua model berhenti di batas 300 epoch sebelum konvergen, sehingga MAE sangat buruk (val 285–399). Pada 10^{-2} pelatihan berhenti setelah sekitar 62–68 epoch dan hasilnya bergantung model: LSTM membaik (val 216 dari 230, test 226 dari 274), GRU setara (val 208), RNN memburuk (val 223 dari 206), dan ANN menjadi tidak stabil (simpangan baku test 53 dibanding 6). Jadi learning rate terbaik berbeda per model, dan urutan model berubah: pada 10^{-2} GRU (216) dan LSTM (226) mengungguli RNN (241).

Kelompok fitur (A5). Menambah fitur hampir selalu membantu pada val MAE: dari *net* saja ke semua fitur, GRU membaik dari 265 menjadi 208, LSTM dari 266 menjadi 230, RNN dari 245 menjadi 206, tetapi ANN hanya dari 261 menjadi 249. Fitur waktu (jam, hari) dan call/sms sama-sama berguna bagi model rekuren, dan gabungan keduanya terbaik. Fitur waktu memberi GRU manfaat paling besar (265 menjadi 213), sesuai dugaan bahwa model rekuren yang memproses jam demi jam dibantu oleh penanda posisi dalam siklus

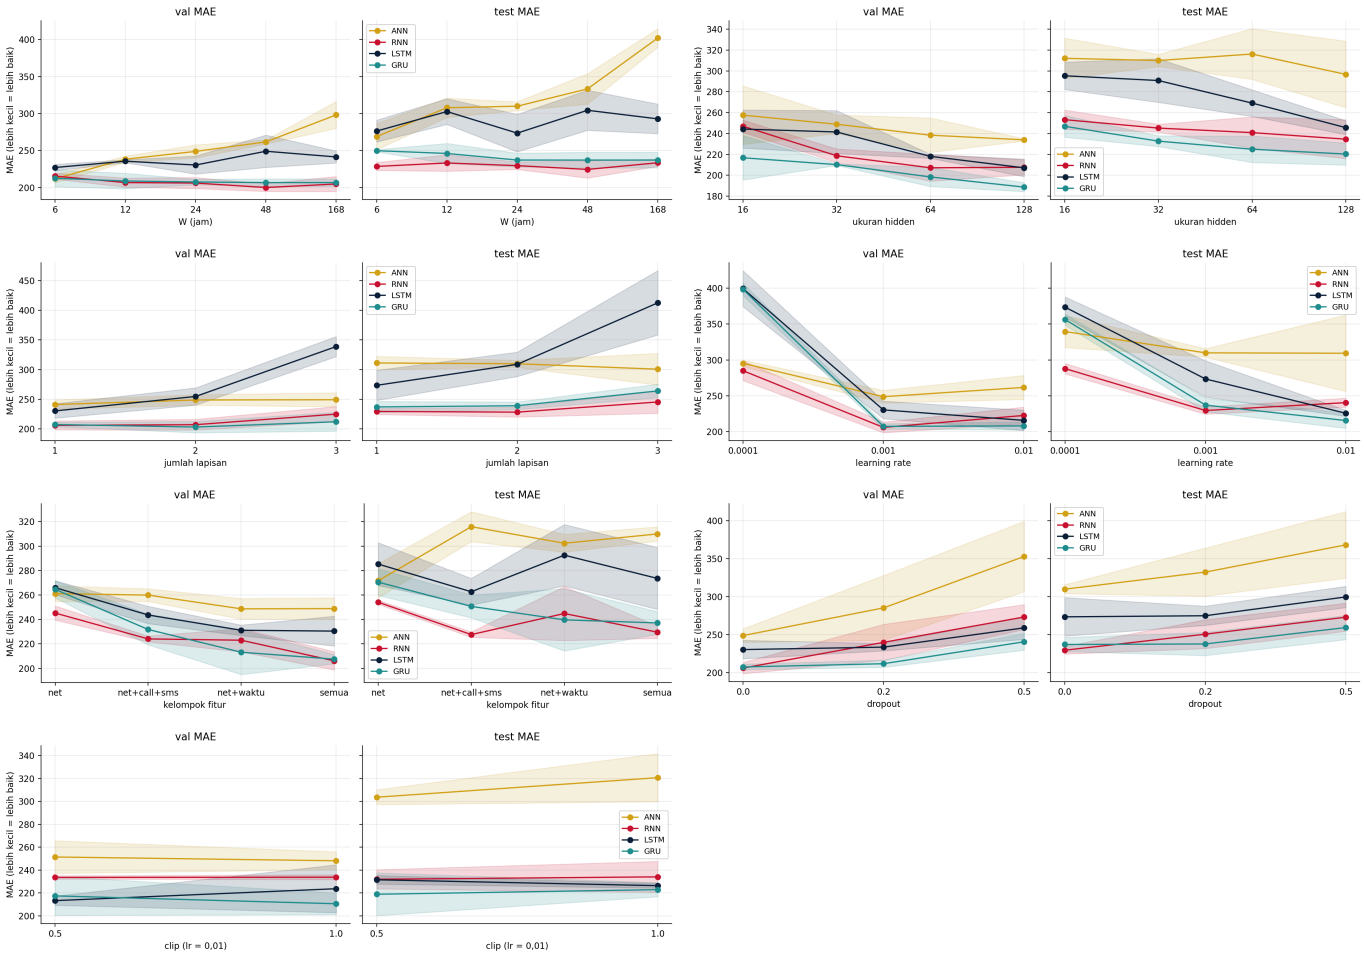


Fig. 2. MAE validasi (kiri) dan test (kanan) tiap panel terhadap nilai faktor; garis per model, area = $\pm$ 1 simpangan baku. Urutan: A1–A5, lalu faktor B.

harian. Perlu dicatat, pada test MAE ANN justru terbaik hanya dengan *net* (272 dibanding 310), konsisten dengan temuan A1 bahwa ANN kewalahan oleh jumlah masukan; pemilihan tetap memakai val MAE.

C. *Ablasi Pilihan*

Pada eksperimen ini, dipilih dua faktor tambahan, yaitu dropout dan gradient clipping. Kedua faktor tersebut dipilih karena memiliki pengaruh terhadap proses pembelajaran model, khususnya dalam mengendalikan overfitting dan menjaga kestabilan pelatihan.

Dropout (B2) Dropout dipilih untuk mengetahui pengaruh regularisasi terhadap kemampuan model dalam mempelajari pola data dan melakukan prediksi pada data yang belum pernah dilihat sebelumnya. Pengujian dilakukan menggunakan tiga nilai, yaitu 0,0 (tanpa dropout), 0,2, dan 0,5.

Hipotesis awal sebelum eksperimen adalah dropout sebesar 0,2 diperkirakan dapat membantu mengurangi overfitting sehingga kemampuan generalisasi model meningkat. Sementara itu, dropout sebesar 0,5 diperkirakan memberikan regularisasi yang lebih kuat, tetapi berpotensi membuat model kesulitan mempelajari pola data karena terlalu banyak neuron yang dinonaktifkan selama pelatihan.

Gradient Clipping (B7) Gradient clipping dipilih untuk mengetahui pengaruh pembatasan nilai gradien terhadap kestabilan proses pelatihan model. Teknik ini digunakan untuk mengurangi risiko exploding gradient, yaitu kondisi ketika nilai gradien menjadi terlalu besar sehingga pembaruan bobot model tidak stabil. Pengujian dilakukan menggunakan nilai batas 0,5 dan 1,0 pada learning rate sebesar 0,01.

Hipotesis awal sebelum eksperimen adalah gradient clipping diperkirakan dapat menjaga kestabilan proses pelatihan dan meningkatkan kemampuan prediksi model. Nilai batas 0,5 diperkirakan memberikan pembatasan gradien yang lebih ketat, sedangkan nilai 1,0 diperkirakan memberikan ruang pembaruan gradien yang lebih besar sehingga proses pembelajaran tetap berjalan dengan baik.

Hasil percobaan menunjukkan bahwa hipotesis awal hanya terbukti sebagian. Gradient clipping mampu meningkatkan kestabilan hasil pada ANN, terlihat dari penurunan simpangan baku test MAE dari 53 menjadi 6 pada batas 0,5. Selain itu, nilai validasi ANN juga mengalami perbaikan. Namun, hasil tersebut tidak berlaku pada seluruh model. RNN justru mengalami peningkatan MAE, sedangkan perubahan pada LSTM dan GRU relatif kecil. Dengan demikian, gradient clipping tidak selalu meningkatkan akurasi, tetapi dapat membantu menjaga kestabilan pelatihan pada kondisi tertentu, khususnya ketika menggunakan learning rate yang tinggi.

TABLE V
KONFIGURASI TERBAIK DIBANDING ACUAN DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

Model	Perubahan dari acuan	Val MAE		Test MAE		Natal MAE	
		acuan	terbaik	acuan	terbaik	acuan	terbaik
ANN	W = 6, hidden = 128, layers = 1	249 ± 9	220 ± 12	310 ± 6	292 ± 27	680 ± 52	569 ± 71
RNN	W = 48, hidden = 64	206 ± 7	213 ± 16	230 ± 5	248 ± 22	421 ± 2	433 ± 54
LSTM	W = 6, hidden = 128, lr = 0.01	230 ± 12	221 ± 15	274 ± 25	244 ± 18	586 ± 57	498 ± 9
GRU	W = 48, hidden = 128, layers = 2	208 ± 4	214 ± 4	237 ± 9	229 ± 6	468 ± 22	445 ± 21

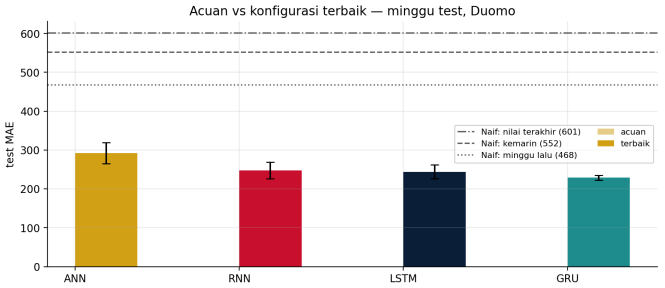


Fig. 3. Test MAE acuan vs terbaik di Duomo; garis putus-putus: baseline naif.

D. Konfigurasi Terbaik

Untuk tiap model, nilai terbaik dari tiap faktor dipilih dengan MAE validasi lalu digabung (Tabel V dan Gambar 3). Gabungan nilai terbaik belum tentu terbaik bersama-sama karena faktor dapat saling memengaruhi. Hasilnya beragam. ANN membaik (val 249 menjadi 220, test 310 menjadi 292) dan LSTM membaik (val 231 menjadi 221, test 274 menjadi 244), sedangkan RNN memburuk (val 206 menjadi 213, test 230 menjadi 248) dan GRU tidak membaik pada val (208 menjadi 214) meski test-nya sedikit turun (237 menjadi 229). Kenaikan val RNN sekitar 3% masih dalam simpangan baku antar seed, tetapi tidak ada perbaikan. Pada minggu Natal, MAE turun untuk ANN, LSTM, dan GRU, namun naik tipis untuk RNN (421 menjadi 433). Konfigurasi gabungan juga jauh lebih besar dari acuan: LSTM 70 ribu dan GRU 152 ribu parameter, dibanding sekitar 5 ribu.

E. Uji Generalisasi

Konfigurasi acuan dan konfigurasi terbaik dari Duomo dilatih ulang tanpa diubah di Stazione Centrale (Tabel VI). Pola trafik kedua lokasi dibandingkan pada Gambar 4. Pada konfigurasi acuan, urutan test MAE di lokasi ini adalah GRU (280 ± 11), RNN (295 ± 11), ANN (331 ± 18), lalu LSTM (337 ± 9), berbeda dari Duomo (RNN, GRU, LSTM, ANN). Error pada minggu Natal jauh lebih besar daripada di Duomo (ANN dan LSTM di atas 1100). Konfigurasi terbaik Duomo tidak menggeneralisasi dengan baik. Di lokasi ini hanya LSTM yang membaik (test 338 menjadi 307, Natal 1219 menjadi 1026). RNN praktis sama (295 menjadi 294), sedangkan ANN memburuk (331 menjadi 343) dan GRU memburuk cukup jelas (280 menjadi 304, Natal 803 menjadi 1017). Urutan test MAE dengan konfigurasi terbaik menjadi RNN, GRU, LSTM, ANN, tetapi GRU dan LSTM berselisih kurang dari simpangan baku.

TABLE VI
GENERALISASI KE STAZIONE CENTRALE: MAE RATA-RATA ± SIMPANGAN BAKU (3 SEED). TIGA BARIS BAWAH: BASELINE NAIF LOKASI INI.

Model	Test MAE		Natal MAE	
	acuan	terbaik	acuan	terbaik
ANN	331 ± 18	343 ± 35	1165 ± 139	1185 ± 68
RNN	295 ± 11	294 ± 15	692 ± 94	631 ± 119
LSTM	337 ± 9	307 ± 12	1219 ± 35	1026 ± 61
GRU	280 ± 11	304 ± 19	803 ± 146	1016 ± 17
Nilai terakhir	582		346	
Kemarin	680		686	
Minggu lalu	445		1673	

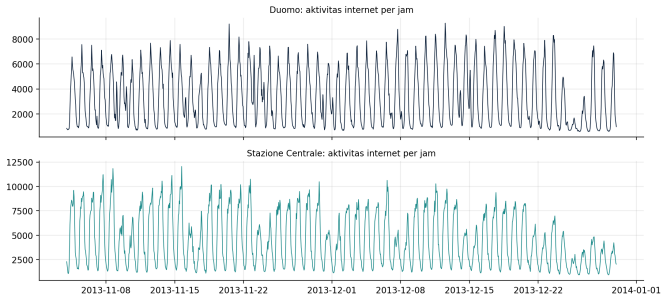


Fig. 4. Aktivitas internet per jam: Duomo (atas) dan Stazione Centrale (bawah).

Pada lokasi Stazione Centrale, seluruh model mengungguli baseline naif pada minggu pengujian. GRU menghasilkan MAE terendah sebesar 280,30, dibandingkan baseline sebesar 445,42. Namun, pada minggu Natal, seluruh model mengalami peningkatan kesalahan prediksi, bahkan melebihi baseline terbaik sebesar 345,60.

Berdasarkan grafik, Duomo memiliki pola aktivitas internet harian yang relatif teratur dengan puncak sekitar 6000–9000. Sementara itu, Stazione Centrale memiliki puncak yang lebih tinggi, mencapai sekitar 10000–12000, tetapi menunjukkan perubahan aktivitas yang lebih besar dan penurunan menjelang akhir Desember. Perbedaan karakteristik tersebut menunjukkan bahwa model yang dilatih pada satu lokasi belum tentu mampu melakukan generalisasi dengan baik pada lokasi lain, terutama ketika terjadi perubahan pola trafik.

IV. PEMBAHASAN

Temuan utama adalah bahwa pilihan hyperparameter dapat mengubah hasil lebih besar daripada perbedaan antar

arsitektur pada acuan. Pada acuan jarak RNN ke GRU hanya sekitar 8 poin test MAE, di dalam simpangan baku antar seed, sedangkan satu model saja dapat bergeser puluhan hingga ratusan poin: LSTM berkisar 226 sampai 413 test MAE antara 10^{-2} dan tiga lapisan, dan ANN berkisar 269 sampai 402 akibat panjang jendela. Karena itu klaim "RNN terbaik" pada acuan sebagian merupakan artefak dari nilai acuan, terbukti dari urutan yang berubah pada 10^{-2} (GRU, LSTM, lalu RNN).

Pola yang berulang adalah bahwa ANN dan model rekuren gagal dengan cara berbeda. ANN rentan terhadap jumlah masukan (A1, sebagian A5) karena parameternya membengkak dengan W padahal sampel hanya 672. Model rekuren berbagi bobot sepanjang waktu sehingga tidak terpengaruh W, tetapi menjadi sensitif terhadap kedalaman dan *learning rate* karena optimisasinya lebih sulit, terutama LSTM dengan empat gerbang. Faktor yang membantu seragam hanyalah kapasitas *hidden* yang lebih besar dan fitur yang lengkap, sedangkan *dropout* merugikan karena model sudah kecil.

Menggabungkan nilai terbaik tiap faktor tidak menjamin gabungan yang terbaik. Dugaan kami ada dua penyebab. Pertama, faktor berinteraksi: nilai yang terbaik saat diuji sendiri diuji di atas faktor acuan lain, misalnya GRU yang memilih hidden 128 dan dua lapisan menjadi 152 ribu parameter, jauh di luar rentang tiap ablasi. Kedua, banyak selisih pada ablasi lebih kecil dari simpangan baku tiga seed (misalnya $W = 48$ vs 24 pada RNN: 200 vs 206), sehingga memilih nilai minimum ikut memilih derau. Di lokasi lain, konfigurasi yang dipilih dengan val Duomo tidak otomatis optimal karena pola trafiknya berbeda; hanya LSTM, yang paling diuntungkan oleh learning rate lebih besar dan hidden lebih besar, tetap membaik.

Keterbatasan studi: hanya satu kota dan satu periode delapan minggu, data latih hanya empat minggu (672 sampel), satu kali pembagian waktu, hanya tiga seed (simpangan baku dari tiga nilai kasar), hanya satu lokasi pembanding untuk generalisasi, dan ablasi satu faktor tidak menangkap interaksi antarfaktor. Ablasi *clipping* dilakukan pada $\mathrm{lr} = 10^{-2}$ sehingga tidak sebanding langsung dengan acuan.

V. Kesimpulan

Pada acuan, RNN terbaik di Duomo (test MAE 230 ± 5), disusul GRU, LSTM, dan ANN, dan semuanya mengalahkan baseline naif terbaik (468). Hasil sangat bergantung pada hyperparameter: *learning rate*, jumlah lapisan (LSTM), panjang jendela (ANN), dan kelompok fitur menggeser MAE puluhan hingga ratusan poin, lebih besar daripada selisih antar model, sedangkan *dropout* merugikan semua model. Menggabungkan nilai terbaik per faktor hanya membantu ANN dan LSTM dan tidak menggeneralisasi ke Stazione Centrale kecuali untuk LSTM. Saran praktisnya: tala *learning rate* dan fitur lebih dulu, evaluasi kombinasi pada data validasi sebelum menganggapnya terbaik, dan uji di lokasi lain.

Kontribusi Anggota

Syarif Hidayatullah	Bagian A1–A5, Penulisan Hasil
Aura Ikhwat Riharja	Bagian C
Revana Tiara Oksanda	Bagian D

Pernyataan Penggunaan AI

Kami menggunakan Claude (Anthropic) sebagai asisten untuk menjelaskan alur pengerjaan, penggunaan Git, GitHub, dan Google Colab, membantu memahami struktur notebook, menyusun sel kode untuk Bagian D, serta menyusun kerangka dan draf laporan ini. Seluruh angka berasal dari run kami sendiri; tabel dihasilkan otomatis dari `hasil/ablasi.csv`, dan interpretasi ditulis serta diperiksa oleh anggota kelompok.

Kami menggunakan Claude (Anthropic) dan ChatGPT (OpenAI) sebagai asisten dalam proses pengerjaan laporan. Penggunaan AI mencakup bantuan dalam memahami alur pengerjaan, penggunaan Git, GitHub, dan Google Colab, memahami struktur notebook, membantu penyusunan dan perbaikan kode untuk Bagian D, serta membantu menyusun dan menyempurnakan penulisan laporan. Seluruh eksperimen dan angka hasil pengujian berasal dari proses pelatihan yang dilakukan oleh kelompok kami. Tabel dihasilkan secara otomatis berdasarkan berkas hasil eksperimen, sedangkan interpretasi dan pembahasan diperiksa serta disesuaikan oleh anggota kelompok.

Kode dan Data

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/syarif124400082-afk/tugas-dl-kelompok-0.

Pustaka

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.

[5] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.